

# 머신러닝 1교시

## — 분류(Classification) 문제 입문 —

### 학습 목표

- 머신러닝의 기본 개념과 학습 방식을 구분할 수 있다.
- 분류(Classification) 문제가 무엇인지 정의하고 실생활 예시를 들 수 있다.
- 대표 데이터셋인 Iris(붓꽃) 데이터를 사이킷런으로 불러올 수 있다.
- 간단한 분류 모델을 학습시키고 정확도를 평가할 수 있다.

### 1. 머신러닝이란 무엇인가?

머신러닝(Machine Learning)은 명시적으로 프로그래밍하지 않아도 컴퓨터가 데이터로부터 스스로 규칙(패턴)을 학습하여 새로운 데이터에 대해 예측하거나 판단하도록 만드는 기술이다. 예를 들어 "스팸 메일을 거르는 규칙"을 사람이 일일이 코드로 작성하는 대신, 수많은 메일 데이터를 모델에게 보여주고 스스로 스팸의 특징을 찾아내게 하는 방식이다.

#### 1.1 머신러닝의 세 가지 학습 방식

| 학습 방식                | 데이터 형태         | 대표 문제        |
|----------------------|----------------|--------------|
| 지도학습 (Supervised)    | 입력 + 정답(label) | 분류, 회귀       |
| 비지도학습 (Unsupervised) | 입력만 (정답 없음)    | 군집화, 차원축소    |
| 강화학습 (Reinforcement) | 환경과의 상호작용      | 게임 AI, 로봇 제어 |

오늘 다룰 분류 문제는 "지도학습"의 대표적인 형태다.

### 2. 분류(Classification) 문제란?

분류는 입력 데이터가 어떤 "범주(category)"에 속하는지 맞추는 문제다. 출력값이 연속적인 수치(키, 가격 등)인 회귀(Regression)와 달리, 분류의 출력은 미리 정해진 클래스 중 하나로 떨어진다.

#### 2.1 분류 vs 회귀

| 구분    | 분류 (Classification) | 회귀 (Regression)   |
|-------|---------------------|-------------------|
| 출력 형태 | 범주(클래스)             | 연속적인 실수값          |
| 예시 1  | 이 메일은 스팸인가? 정상인가?   | 내일 서울의 최고기온은 몇 도? |

|      |                     |                |
|------|---------------------|----------------|
| 예시 2 | 이 사진은 고양이/개/새 중 무엇? | 이 집은 얼마에 팔릴까?  |
| 예시 3 | 이 환자는 양성/음성?        | 환자의 회복 기간은 며칠? |

## 2.2 이진 분류와 다중 분류

- 이진 분류(Binary): 클래스가 2개 — 예) 스팸/정상, 양성/음성
- 다중 분류(Multiclass): 클래스가 3개 이상 — 예) 손글씨 숫자(0~9), 붓꽃 품종 3종

## 2.3 실생활 속 분류 문제 예시

- 이메일 스팸 필터 (스팸 / 정상)
- 신용카드 부정거래 탐지 (정상 / 사기)
- 의료 영상 진단 (정상 / 이상 / 종양 종류)
- 얼굴 인식, 음성 인식, 감정 분석
- 농작물 품종 자동 식별

## 3. 분류에 자주 쓰이는 알고리즘

| 알고리즘           | 특징            | 장점            |
|----------------|---------------|---------------|
| 로지스틱 회귀        | 확률 기반 선형 분류   | 간단, 해석 용이     |
| K-최근접 이웃 (KNN) | 가까운 이웃의 다수결   | 직관적, 학습 빠름    |
| 결정트리           | 질문을 반복해 분류    | 해석성 매우 높음     |
| 랜덤 포레스트        | 결정트리 여러 개 앙상블 | 성능 우수, 과적합 적음 |
| SVM            | 클래스 사이 마진 최대화 | 고차원에 강함       |

## 4. 유명 데이터셋: 붓꽃(Iris) 데이터

Iris 데이터셋은 1936년 통계학자 Ronald Fisher가 발표한 데이터로, 머신러닝 입문에서 가장 널리 사용되는 "Hello World" 데이터셋이다. 3가지 붓꽃 품종(setosa, versicolor, virginica) 각 50개씩, 총 150개 샘플로 구성된다.

### 4.1 데이터 구조

샘플 수 : 150개 (품종별 50개)

특성(feature) 수: 4개

특성 : 꽃받침 길이, 꽃받침 너비, 꽃잎 길이, 꽃잎 너비 (단위: cm)

클래스(타겟) : setosa(0), versicolor(1), virginica(2)

문제 유형 : 다중 분류 (3-class classification)

## 5. 사이킷런(scikit-learn) 코드 실습

scikit-learn은 파이썬 머신러닝 표준 라이브러리다. 아래 코드를 한 줄씩 따라 실행하며 분류 모델이 만들어지는 흐름을 익혀보자.

### 실습 환경 준비

```
# 필요한 라이브러리 설치 (터미널에서)
pip install scikit-learn pandas matplotlib
```

### [1단계] 데이터 불러오기

```
from sklearn.datasets import load_iris
import pandas as pd

# Iris 데이터 로드
iris = load_iris()

print("특성 이름:", iris.feature_names)
print("클래스 이름:", iris.target_names)
print("데이터 모양:", iris.data.shape) # (150, 4)
print("타겟 모양:", iris.target.shape) # (150,)
```

### [2단계] 데이터 살펴보기

```
# DataFrame으로 변환해서 보기 좋게 출력
df = pd.DataFrame(iris.data, columns=iris.feature_names)
df["species"] = [iris.target_names[i] for i in iris.target]

print(df.head()) # 앞 5개 행
print(df["species"].value_counts()) # 클래스별 개수
```

### [3단계] 훈련세트 / 테스트세트 분리

모델이 처음 보는 데이터에서도 잘 맞는지 확인하려면, 데이터를 훈련용(train)과 시험용(test)으로 나눠야 한다.

```
from sklearn.model_selection import train_test_split

X = iris.data # 입력 (4개 특성)
y = iris.target # 정답 (품종)

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2, # 20%를 테스트용
    random_state=42, # 재현 가능하도록 고정
    stratify=y # 클래스 비율 유지
)

print("훈련 데이터:", X_train.shape) # (120, 4)
print("테스트 데이터:", X_test.shape) # (30, 4)
```

### [4단계] 모델 학습 — KNN

```
from sklearn.neighbors import KNeighborsClassifier

# 가장 가까운 이웃 3개를 보고 다수결로 분류
knn = KNeighborsClassifier(n_neighbors=3)
knn.fit(X_train, y_train) # 학습

# 예측
y_pred = knn.predict(X_test)
print("예측 결과:", y_pred)
print("실제 정답:", y_test)
```

## [5단계] 모델 평가

```
from sklearn.metrics import accuracy_score, confusion_matrix,
classification_report

acc = accuracy_score(y_test, y_pred)
print(f"정확도: {acc:.4f}")          # 보통 0.97 ~ 1.00

print("\n혼동 행렬:")
print(confusion_matrix(y_test, y_pred))

print("\n상세 리포트:")
print(classification_report(y_test, y_pred,
                             target_names=iris.target_names))
```

## [6단계] 다른 모델과 비교 — 결정트리

```
from sklearn.tree import DecisionTreeClassifier

tree = DecisionTreeClassifier(random_state=42)
tree.fit(X_train, y_train)

tree_pred = tree.predict(X_test)
print("결정트리 정확도:", accuracy_score(y_test, tree_pred))

# 어떤 특성이 분류에 중요했는가?
for name, imp in zip(iris.feature_names, tree.feature_importances_):
    print(f"{name}: {imp:.3f}")
```

## [7단계] 새로운 꽃 한 송이 예측해보기

```
# 꽃받침 길이=5.1, 너비=3.5, 꽃잎 길이=1.4, 너비=0.2 인 꽃은?
new_flower = [[5.1, 3.5, 1.4, 0.2]]

pred = knn.predict(new_flower)
print("예측 품종:", iris.target_names[pred[0]])
# 출력 예: 예측 품종: setosa
```

# 6. 오늘 수업 정리

- 머신러닝은 데이터로부터 규칙을 스스로 배우는 기술이다.
- 분류는 입력이 어떤 "범주"에 속하는지 맞히는 지도학습 문제다.
- 사이킷런은 "데이터 불러오기 → 분리 → 학습(fit) → 예측(predict) → 평가"의 일관된 흐름을 제공한다.
- Iris 데이터로 KNN과 결정트리를 학습시켜 보았고, 두 모델 모두 90% 이상의 정확도를 보였다.

## 과제

- KNN의 `n_neighbors`를 1, 3, 5, 10, 20으로 바꿔보고 정확도가 어떻게 변하는지 정리.
- `load_wine()` 데이터셋을 같은 절차로 분류해보고, Iris와 비교해 어떤 점이 어려웠는지.